

Universidad de San Carlos de Guatemala

Facultad de Ingeniería

Ingeniería en Ciencias y Sistemas

Metodología de Sistemas

Proyecto Fase 1
Procesamiento y Análisis Exploratorio de Datos Masivos en
BigQuery



Ponderación: 25 puntos

Horas aproximadas de aprendizaje: 22 horas

Índice

Resumen Ejecutivo	1
Competencias que desarrollar	1
Objetivos	1
General	1
Específicos	1
Enunciado	2
Descripción del problema a resolver	2
Alcance de la práctica	2
Requerimientos técnicos	3
Entregables	4
Consideraciones	5
Cronograma	7
Rúbrica de calificación	8
Valores	9
Referencias	10

Resumen Ejecutivo

El crecimiento exponencial de los datos generados diariamente plantea grandes retos para su almacenamiento, procesamiento y análisis. En este proyecto, los estudiantes trabajarán con el **dataset público de New York City Taxi Trips 2022**, disponible en **Google BigQuery**, que contiene más de 100 millones de registros de viajes de taxi en la ciudad de Nueva York.

El objetivo de esta fase es que los estudiantes desarrollen competencias en análisis exploratorio de datos masivos utilizando **SQL en BigQuery**, aplicando técnicas de transformación y optimización de consultas mediante **particiones y clustering**, y documentando hallazgos relevantes sobre patrones de viaje, costos y comportamiento de usuarios.

Al finalizar la fase, los estudiantes habrán diseñado consultas eficientes sobre grandes volúmenes de datos, explorado relaciones entre variables (tiempo, distancia, costo, forma de pago, ubicación geográfica) y generado visualizaciones iniciales en **Google Sheets o Data Studio** para comunicar los resultados de manera clara. Este trabajo servirá como base para la Fase 2, donde se construirán modelos predictivos con **BigQuery ML** a partir del dataset ya procesado y optimizado.

Competencias que desarrollar

Administra proyectos de análisis de datos en la nube con herramientas como BigQuery y Google Cloud Platform aplicando principios de gobierno de datos, seguridad y control de acceso.

Objetivos

General

- Diseñar e implementar un proceso de análisis exploratorio y optimización de datos masivos en Google BigQuery, aplicando transformaciones SQL, particiones y clustering, para detectar patrones relevantes y comunicar los hallazgos mediante visualizaciones en herramientas de Google Cloud.

Específicos

- Conectarse al dataset público de NYC Taxi Trips 2022 en BigQuery, con más de 100 millones de registros.

- Aplicar consultas SQL avanzadas para filtrar, agrupar, calcular métricas y preparar datos para el análisis.
- Optimizar consultas mediante particiones y clustering, comparando costos de procesamiento y beneficios obtenidos.
- Explorar patrones y tendencias en los datos (temporales, categóricos, geográficos y económicos).
- Generar visualizaciones iniciales en Google Sheets o Data Studio que resuman los hallazgos más relevantes.
- Documentar los resultados en un repositorio estructurado con scripts SQL, capturas de consultas, informe visual y README técnico.

Enunciado

Descripción del problema a resolver

El análisis de grandes volúmenes de datos se ha convertido en un desafío crítico para las organizaciones. Cuando los datos no están optimizados, las consultas pueden resultar lentas y costosas, dificultando la toma de decisiones en tiempo real. En este proyecto, los estudiantes deberán abordar este reto utilizando el dataset público NYC Taxi Trips 2022 en BigQuery, que contiene más de 100 millones de registros de viajes. La tarea consiste en aplicar consultas SQL y técnicas de optimización (particiones y clustering) para transformar los datos en información útil, identificar patrones significativos y generar visualizaciones que apoyen un análisis exploratorio claro y efectivo.

Alcance del proyecto

El equipo deberá:

1. Conectarse al dataset público:
 - `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`.
2. Realizar consultas SQL para:
 - Calcular métricas descriptivas (distancia promedio, duración, tarifas, propinas).

- Analizar la distribución de variables categóricas (método de pago, cantidad de pasajeros).
 - Detectar patrones temporales (mes, día, hora).
3. Crear tablas derivadas en su propio proyecto para trabajar subsets optimizados del dataset.
 4. Implementar **particiones por fecha** y **clustering por ubicaciones** para reducir el costo de procesamiento.
 5. Comparar el rendimiento de consultas antes y después de aplicar optimización.
 6. Exportar o enlazar resultados a **Google Sheets o Data Studio** para generar al menos 2–3 visualizaciones exploratorias.
 7. Documentar el proceso en un repositorio organizado, incluyendo scripts SQL, capturas de consultas y un informe visual.

Requerimientos técnicos

Cuenta activa en Google Cloud Platform (GCP) con créditos gratuitos habilitados.

Acceso al servicio **BigQuery** en el proyecto personal de cada estudiante o grupo.

Dataset público: `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`.

Consultas SQL con uso de:

- Funciones agregadas (AVG, COUNT, SUM, MIN, MAX).
- Funciones temporales (EXTRACT, TIMESTAMP_DIFF).
- Filtros y agrupaciones.

Implementación de:

- **Particiones** (por `pickup_datetime` o `data_file_month`).
- **Clustering** (por `pickup_location_id` y `dropoff_location_id`).

Visualización con **Google Sheets o Google Data Studio (Looker Studio)**.

Repositorio en GitHub con estructura clara y README técnico.

Entregables

Cada equipo deberá crear un repositorio en GitHub con el nombre:

SS2_2S2025_#Grupo

Dentro del repositorio deberá existir una carpeta llamada **Fase_1**, que contendrá lo siguiente:

1. Scripts SQL

- Archivo(s) .sql con las consultas realizadas en BigQuery para exploración, transformaciones y optimización (particiones y clustering).
- El archivo debe estar debidamente comentado para explicar la finalidad de cada bloque de consulta.

2. Evidencias

- Capturas de pantalla de la ejecución de consultas relevantes en BigQuery (ejemplo: conteo de registros, partición aplicada, reducción de costo en bytes procesados).
- En caso de usar tablas derivadas en su proyecto, incluir evidencia de su creación.

3. Informe visual

- Enlace a un tablero de **Google Data Studio (Looker Studio)** o archivo de **Google Sheets** enlazado a BigQuery.
- Debe incluir al menos 2–3 visualizaciones exploratorias que resuman hallazgos clave (ej. viajes por mes, distribución de métodos de pago, promedio de tarifas por hora).

4. Archivo README (README.md)

- El README debe documentar:
 1. Nombre del proyecto y del equipo (integrantes).
 2. Dataset utilizado y descripción breve.
 3. Transformaciones y consultas realizadas.

4. Técnicas de optimización aplicadas (particiones y clustering), con comparación de costos antes y después.
5. Patrones o hallazgos relevantes identificados.
6. Enlace al informe visual en Google Sheets o Data Studio.

5. Organización del repositorio

- Estructura clara de carpetas y archivos.
- Nombres de archivos consistentes.
- Incluir al tutor como colaborador con permisos de lectura.

Consideraciones

Uso del dataset público

- El proyecto debe desarrollarse únicamente con el dataset **bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022**.
- No se permite reemplazarlo por datasets más pequeños o distintos, salvo para generar **tablas derivadas optimizadas** dentro del proyecto personal.

Trabajo en la nube

- Todo el procesamiento debe realizarse en **Google BigQuery** y la visualización en **Google Sheets o Data Studio (Looker Studio)**.
- No se aceptarán soluciones implementadas únicamente en entornos locales (ej. Python o Excel), salvo como apoyo complementario.

Optimización obligatoria

- Es obligatorio demostrar el uso de **particiones y clustering** en al menos una tabla derivada.
- Se debe incluir evidencia de la **reducción en bytes procesados** antes y después de la optimización.

Organización del repositorio

- El repositorio debe seguir la convención de nombres **SS2_2S2025_#Grupo**.
- Todo el material de esta fase debe estar dentro de la carpeta **Fase_1**.
- Se penalizará la falta de estructura o entregables incompletos.

Accesos al tutor

- El tutor debe estar agregado como lector/colaborador en el repositorio y en los recursos compartidos (Google Sheets o Data Studio).

Originalidad y ética académica

- Cada equipo debe desarrollar su propio proyecto.
- Se prohíbe la copia total o parcial de consultas, dashboards o documentación entre grupos.
- El uso de código, tutoriales o ejemplos externos está permitido únicamente si se referencian correctamente.

Penalizaciones

- La falta de documentación, repositorios incompletos o no incluir evidencias reducirá la calificación de forma proporcional.
- Si se detecta plagio o duplicación de entregables entre equipos, la calificación de la fase será **0 puntos**.

Cronograma

Tarea	Fecha
Asignación de la práctica / Entrega del enunciado	03 de septiembre
Fecha de entrega	26 de septiembre
Fecha de calificación	27 de septiembre

Rúbrica de calificación

Criterio	Descripción del criterio a evaluar	Puntos Máximos
Conexión y uso del dataset	Uso correcto del dataset público, validación de registros y calidad de datos.	15 pts.
Consultas SQL y transformaciones	Aplicación de consultas SQL con filtros, funciones, agrupaciones y métricas clave.	25 pts.
Optimización con particiones y clustering	Creación de tablas derivadas optimizadas, con evidencia de reducción de bytes procesados.	20 pts.
Análisis de patrones y tendencias	Identificación y explicación de hallazgos relevantes en variables temporales, categóricas o geográficas.	20 pts.
Visualización de resultados	Tablero en Google Sheets/Data Studio con mínimo 2–3 visualizaciones claras y funcionales.	15 pts.
Documentación técnica (README)	Explica dataset, transformaciones, optimización aplicada, hallazgos y enlace al informe visual.	5 pts.

Valores

En el desarrollo de la práctica, se espera que cada estudiante demuestre honestidad académica y profesionalismo. Por lo tanto, se establecen los siguientes principios:

- **Originalidad del Trabajo**
 - Cada estudiante o equipo debe desarrollar su propio código y/o documentación, aplicando los conocimientos adquiridos en el curso.
- **Prohibición de Copias y Plagio**
 - Si se detecta la copia total o parcial del código, documentación o cualquier otro entregable, la calificación será de **0 puntos**.
 - Esto incluye la reproducción de código entre compañeros, la reutilización de proyectos de semestres anteriores o el uso de código externo sin la debida referencia.
- **Uso Responsable de Recursos Externos**
 - El uso de bibliotecas, Frameworks y ejemplos de código externos está permitido, siempre y cuando se referencian correctamente y se comprendan plenamente. (Consultar con el catedrático su política)
- **Revisión y Detección de Plagio**
 - Se podrán utilizar herramientas automatizadas y revisiones manuales para identificar similitudes en los proyectos.
 - En caso de sospecha, el estudiante deberá justificar su código y demostrar su desarrollo individual o en equipo. Si este extremo no es comprobable la calificación será de **0 puntos**.
 - Al detectarse estos aspectos se informará al catedrático del curso quien realizará las acciones que considere oportunas.

Referencias

- Google Cloud. (s. f.). **BigQuery Documentation**. Recuperado de: <https://cloud.google.com/bigquery/docs>
- Google Cloud. (s. f.). **Introduction to BigQuery datasets**. Recuperado de: <https://cloud.google.com/bigquery/docs/datasets-intro>
- Google Cloud. (s. f.). **BigQuery Public Datasets**. Recuperado de: <https://cloud.google.com/bigquery/public-data>
- Google Cloud. (s. f.). **Partitioned tables**. Recuperado de: <https://cloud.google.com/bigquery/docs/partitioned-tables>
- Google Cloud. (s. f.). **Clustered tables**. Recuperado de: <https://cloud.google.com/bigquery/docs/clustered-tables>
- Google Cloud. (s. f.). **Looker Studio (Data Studio) Documentation**. Recuperado de: <https://cloud.google.com/looker/docs/studio>