

Universidad de San Carlos de Guatemala

Facultad de Ingeniería

Ingeniería en Ciencias y Sistemas

Metodología de Sistemas

Proyecto Fase 1

Modelado Predictivo con BigQuery ML



Ponderación: 25 puntos

Horas aproximadas de aprendizaje: 27 horas

Índice

Resumen Ejecutivo	1
Competencias que desarrollar	1
Objetivos	1
General	1
Específicos	1
Enunciado	1
Descripción del problema a resolver	2
Alcance de la práctica	3
Requerimientos técnicos	3
Entregables	4
Consideraciones	5
Cronograma	7
Rúbrica de calificación	8
Valores	9
Referencias	10

Resumen Ejecutivo

Luego del análisis exploratorio y la optimización realizada en la Fase 1, los estudiantes continuarán el ciclo de análisis de datos aplicando técnicas de **Machine Learning directamente en BigQuery**. El objetivo central de esta fase es **construir, entrenar y evaluar modelos predictivos con BigQuery ML**, utilizando como base el dataset de NYC Taxi Trips 2022 previamente procesado.

El trabajo consistirá en preparar un conjunto de datos de entrenamiento y prueba, seleccionar variables relevantes, entrenar al menos dos modelos predictivos distintos y comparar su desempeño mediante métricas estadísticas. Con ello, los estudiantes experimentarán de manera práctica cómo los modelos de aprendizaje automático permiten identificar patrones complejos y realizar predicciones que aporten valor en escenarios de negocio.

Al finalizar, se espera que los equipos integren las predicciones en un tablero visual, contrastando los valores reales frente a los predichos, y documenten de forma clara el flujo de modelado, sus hallazgos y las implicaciones de los resultados. Esta fase representa un paso fundamental hacia la consolidación de competencias avanzadas en analítica y Business Intelligence, utilizando únicamente herramientas de Google Cloud.

Competencias que desarrollar

Administra proyectos de análisis de datos en la nube con herramientas como BigQuery y Google Cloud Platform aplicando principios de gobierno de datos, seguridad y control de acceso.

Objetivos

General

- Diseñar y evaluar modelos predictivos en BigQuery ML que permitan analizar patrones complejos del dataset NYC Taxi Trips 2022, generando predicciones contrastadas con valores reales y comunicando los hallazgos de forma visual y técnica.

Específicos

- Seleccionar un subconjunto de datos optimizado a partir de las tablas de la Fase 1, con las variables más relevantes para el modelado.

- Dividir los datos en conjuntos de entrenamiento y prueba, garantizando una proporción adecuada para la evaluación del modelo.
- Entrenar al menos dos modelos predictivos diferentes (por ejemplo, regresión lineal vs. árboles potenciados para predicción de propinas).
- Evaluar los modelos utilizando funciones de BigQuery ML como ML.EVALUATE y comparar su desempeño con métricas adecuadas (RMSE, MAE, accuracy, etc.).
- Generar predicciones con ML.PREDICT y analizarlas en relación con los valores reales del dataset.
- Visualizar los resultados en un tablero interactivo (Google Data Studio o Google Sheets), destacando la comparación entre resultados reales y predichos.
-

Enunciado

Descripción del problema a resolver

Las organizaciones modernas no solo buscan entender qué ocurrió en el pasado, sino anticiparse a lo que ocurrirá en el futuro. En este proyecto, los estudiantes deberán aplicar técnicas de aprendizaje automático para construir modelos que predigan variables clave del negocio de transporte urbano.

Se deberá seleccionar un caso de predicción relevante a partir del dataset (ej. monto de propina, duración de viaje, probabilidad de que exista propina). A partir de esa selección, los equipos tendrán que entrenar al menos dos modelos diferentes en BigQuery ML, comparar sus métricas de desempeño y justificar cuál se adapta mejor al problema planteado.

Finalmente, los resultados deberán presentarse en un tablero visual que permita observar de forma clara la relación entre valores reales y predichos, demostrando la aplicabilidad práctica del modelo en contextos de análisis de negocio.

Alcance del proyecto

El equipo deberá:

1. Utilizar las tablas derivadas optimizadas con particiones y clustering creadas en la Fase 1 como base de datos.
2. Seleccionar las variables independientes (features) más relevantes y la variable dependiente a predecir.
3. Dividir los datos en conjuntos de entrenamiento y prueba, aplicando buenas prácticas de validación.
4. Entrenar al menos **dos modelos diferentes** en BigQuery ML (LINEAR_REG, LOGISTIC_REG, BOOSTED_TREE, etc.).
5. Evaluar el rendimiento de los modelos mediante métricas provistas por ML.EVALUATE.
6. Comparar los resultados de ambos modelos y justificar cuál presenta mejor desempeño.
7. Generar predicciones sobre un conjunto de prueba con ML.PREDICT.
8. Diseñar un dashboard en Looker Studio o Sheets que muestre al menos:
 - a. Comparación entre valores reales y predichos.
 - b. Visualización de las predicciones en relación con variables relevantes.
9. Documentar el proceso en el repositorio con scripts, capturas, informe visual y README técnico.

Requerimientos técnicos

- Cuenta activa en Google Cloud Platform (GCP) con créditos disponibles.
- Acceso al servicio BigQuery y al dataset optimizado de la Fase 1.
- Uso de sentencias SQL de BigQuery ML:
 - CREATE OR REPLACE MODEL
 - ML.TRAINING_INFO
 - ML.EVALUATE
 - ML.PREDICT

- Tablero visual en Google Sheets o Looker Studio enlazado a los resultados de predicciones.
- Repositorio en GitHub con estructura clara y documentación organizada.

Entregables

Cada equipo deberá crear un repositorio en GitHub con el nombre:

SS2_2S2025_#Grupo

Dentro del repositorio deberá existir una carpeta llamada **Fase_1**, que contendrá lo siguiente:

1. **Scripts SQL** con la creación, entrenamiento, evaluación y predicción de los modelos.
2. **Evidencias** en forma de capturas de pantalla de:
 - Entrenamiento de modelos.
 - Métricas de evaluación.
 - Resultados de predicciones.
3. **Informe visual** con el enlace a un tablero de Google Sheets o Data Studio que muestre valores reales vs predichos.
4. **README.md** documentando:
 - Objetivo del modelado.
 - Dataset y variables utilizadas.
 - Modelos implementados y justificación.
 - Comparación de métricas y hallazgos relevantes.
 - Enlace al tablero visual.

Consideraciones

Uso del dataset y alcance

- Trabajar exclusivamente con el dataset público **NYC Taxi Trips 2022** y con las **tablas derivadas optimizadas** creadas en Fase 1 (particiones y clustering).
- Se permiten tablas/vistas derivadas **solo dentro** del proyecto del equipo para preparación de features y particiones adicionales.
- No se aceptan sustituciones por datasets distintos ni muestreos que alteren la distribución sin justificarlo.

Selección del problema y métrica principal

- Definir explícitamente la **variable objetivo** (ej. propina, duración, propina sí/no) y la **métrica primaria** de evaluación acorde al tipo de problema (ej. RMSE/MAE para regresión; AUC/accuracy/log loss para clasificación).
- Mantener consistencia: todas las comparaciones entre modelos deben usar la **misma partición de evaluación** y la misma métrica principal.

Preparación del conjunto de datos

- Evitar **fugas de información** (data leakage): las transformaciones que usen el objetivo o datos del futuro deben aplicarse **después** de dividir train/test.
- Documentar la estrategia de división (por tiempo o aleatoria) y su razón de ser. Si se usa división aleatoria, dejar evidencia de la proporción usada.

Ingeniería de características (features)

- Justificar las variables elegidas y, cuando aplique, crear **features derivadas** (p. ej., hora del día, día de la semana, binning de distancia, interacciones sencillas).
- Tratar valores atípicos y nulos de forma consistente; explicar decisiones (recorte, imputación, exclusión).

Modelado en BigQuery ML

- Entrenar **al menos dos modelos** de enfoques distintos (p. ej., regresión lineal vs. árbol potenciado; o logística vs. árbol potenciado para clasificación).
- Documentar **opciones/hyperparámetros** usados en CREATE MODEL y cualquier ajuste realizado.
- Registrar ML.TRAINING_INFO como evidencia del proceso de entrenamiento.

Evaluación y comparación

- Usar ML.EVALUATE para obtener métricas; presentar una **tabla comparativa** por modelo con la métrica primaria y secundarias.
- Justificar la **selección del modelo final** con base en métricas y consideraciones de interpretabilidad/costo.

Predicciones e integración

- Generar predicciones con ML.PREDICT sobre el **conjunto de prueba** (o un holdout temporal) y **guardar** los resultados en una tabla/vista para el dashboard.
- Para el tablero, contrastar **valor real vs. predicho** y añadir visualizaciones que expliquen el comportamiento por variables relevantes (p. ej., error por hora del día).

Costos y desempeño

- Evitar SELECT *; proyectar solo las columnas necesarias.
- Preferir consultas sobre tablas **particionadas** y **clusterizadas**; filtrar por partición en todas las consultas de entrenamiento/evaluación/predicción.
- Realizar **dry-runs/estimación de bytes** antes de ejecuciones pesadas y capturar evidencia de reducción de bytes cuando corresponda.

Reproducibilidad y organización

- Versionar scripts SQL y nombrar consistentemente datasets, tablas, vistas y modelos (ej.: fase2_model_linreg_propina, predicciones_propina_test).

- Incluir en el README: esquema final de features, lógica de división, hyperparámetros, métricas y enlace al tablero.
- Agregar al tutor con permisos de lectura en **repositorio** y recursos compartidos (Sheets/Looker Studio).

Alcance de herramientas

- El modelado debe realizarse **en BigQuery ML**. Herramientas locales (Python/Excel) se permiten solo como apoyo y **no** sustituyen el flujo principal ni los entregables.

Ética y sesgos

- Incluir un breve comentario sobre **posibles sesgos** del dataset (p. ej., por zona/horario) y las implicaciones para el uso de predicciones en decisiones de negocio.

Cronograma

Tarea	Fecha
Asignación de la práctica / Entrega del enunciado	24 de septiembre
Fecha de entrega	24 de octubre
Fecha de calificación	25 de octubre

Rúbrica de calificación

Criterio	Descripción del criterio a evaluar	Puntos Máximos
Preparación del dataset	Selección de variables, división train/test, limpieza adecuada.	15 pts.
Entrenamiento de modelos	Implementación de al menos dos modelos distintos en BigQuery ML, con justificación clara.	25 pts.
Evaluación de modelos	Uso de ML.EVALUATE, interpretación y comparación de métricas.	20 pts.
Predicciones y análisis	Ejecución de ML.PREDICT, análisis de resultados y hallazgos.	20 pts.
Visualización de resultados	Tablero que muestre valores reales vs predichos de manera clara y relevante.	15 pts.
Documentación técnica (README)	Explica dataset, transformaciones, optimización aplicada, hallazgos y enlace al informe visual.	5 pts.

Valores

En el desarrollo de la práctica, se espera que cada estudiante demuestre honestidad académica y profesionalismo. Por lo tanto, se establecen los siguientes principios:

- **Originalidad del Trabajo**
 - Cada estudiante o equipo debe desarrollar su propio código y/o documentación, aplicando los conocimientos adquiridos en el curso.
- **Prohibición de Copias y Plagio**
 - Si se detecta la copia total o parcial del código, documentación o cualquier otro entregable, la calificación será de **0 puntos**.
 - Esto incluye la reproducción de código entre compañeros, la reutilización de proyectos de semestres anteriores o el uso de código externo sin la debida referencia.
- **Uso Responsable de Recursos Externos**
 - El uso de bibliotecas, Frameworks y ejemplos de código externos está permitido, siempre y cuando se referencian correctamente y se comprendan plenamente. (Consultar con el catedrático su política)
- **Revisión y Detección de Plagio**
 - Se podrán utilizar herramientas automatizadas y revisiones manuales para identificar similitudes en los proyectos.
 - En caso de sospecha, el estudiante deberá justificar su código y demostrar su desarrollo individual o en equipo. Si este extremo no es comprobable la calificación será de **0 puntos**.
 - Al detectarse estos aspectos se informará al catedrático del curso quien realizará las acciones que considere oportunas.

Referencias

- Google Cloud. (s. f.). *BigQuery ML overview*. Recuperado de: <https://cloud.google.com/bigquery-ml/docs>
- Google Cloud. (s. f.). *CREATE MODEL statement*. Recuperado de: <https://cloud.google.com/bigquery-ml/docs/create-model>
- Google Cloud. (s. f.). *ML.EVALUATE function*. Recuperado de: <https://cloud.google.com/bigquery-ml/docs/reference/standard-sql/bigqueryml-syntax-ml-evaluate>
- Google Cloud. (s. f.). *ML.PREDICT function*. Recuperado de: <https://cloud.google.com/bigquery-ml/docs/reference/standard-sql/bigqueryml-syntax-ml-predict>
- Google Cloud. (s. f.). *ML.EXPLAIN_PREDICT function*. Recuperado de: <https://cloud.google.com/bigquery-ml/docs/reference/standard-sql/bigqueryml-syntax-ml-explain-predict>
- Google Cloud. (s. f.). *Regression models in BigQuery ML*. Recuperado de: <https://cloud.google.com/bigquery-ml/docs/regression-predict>
- Google Cloud. (s. f.). *Classification models in BigQuery ML*. Recuperado de: <https://cloud.google.com/bigquery-ml/docs/classification-overview>
- Google Cloud. (s. f.). *Boosted tree models*. Recuperado de: <https://cloud.google.com/bigquery-ml/docs/boosted-tree-intro>
- Google Cloud. (s. f.). *Looker Studio (Data Studio) Documentation*. Recuperado de: <https://cloud.google.com/looker/docs/studio>